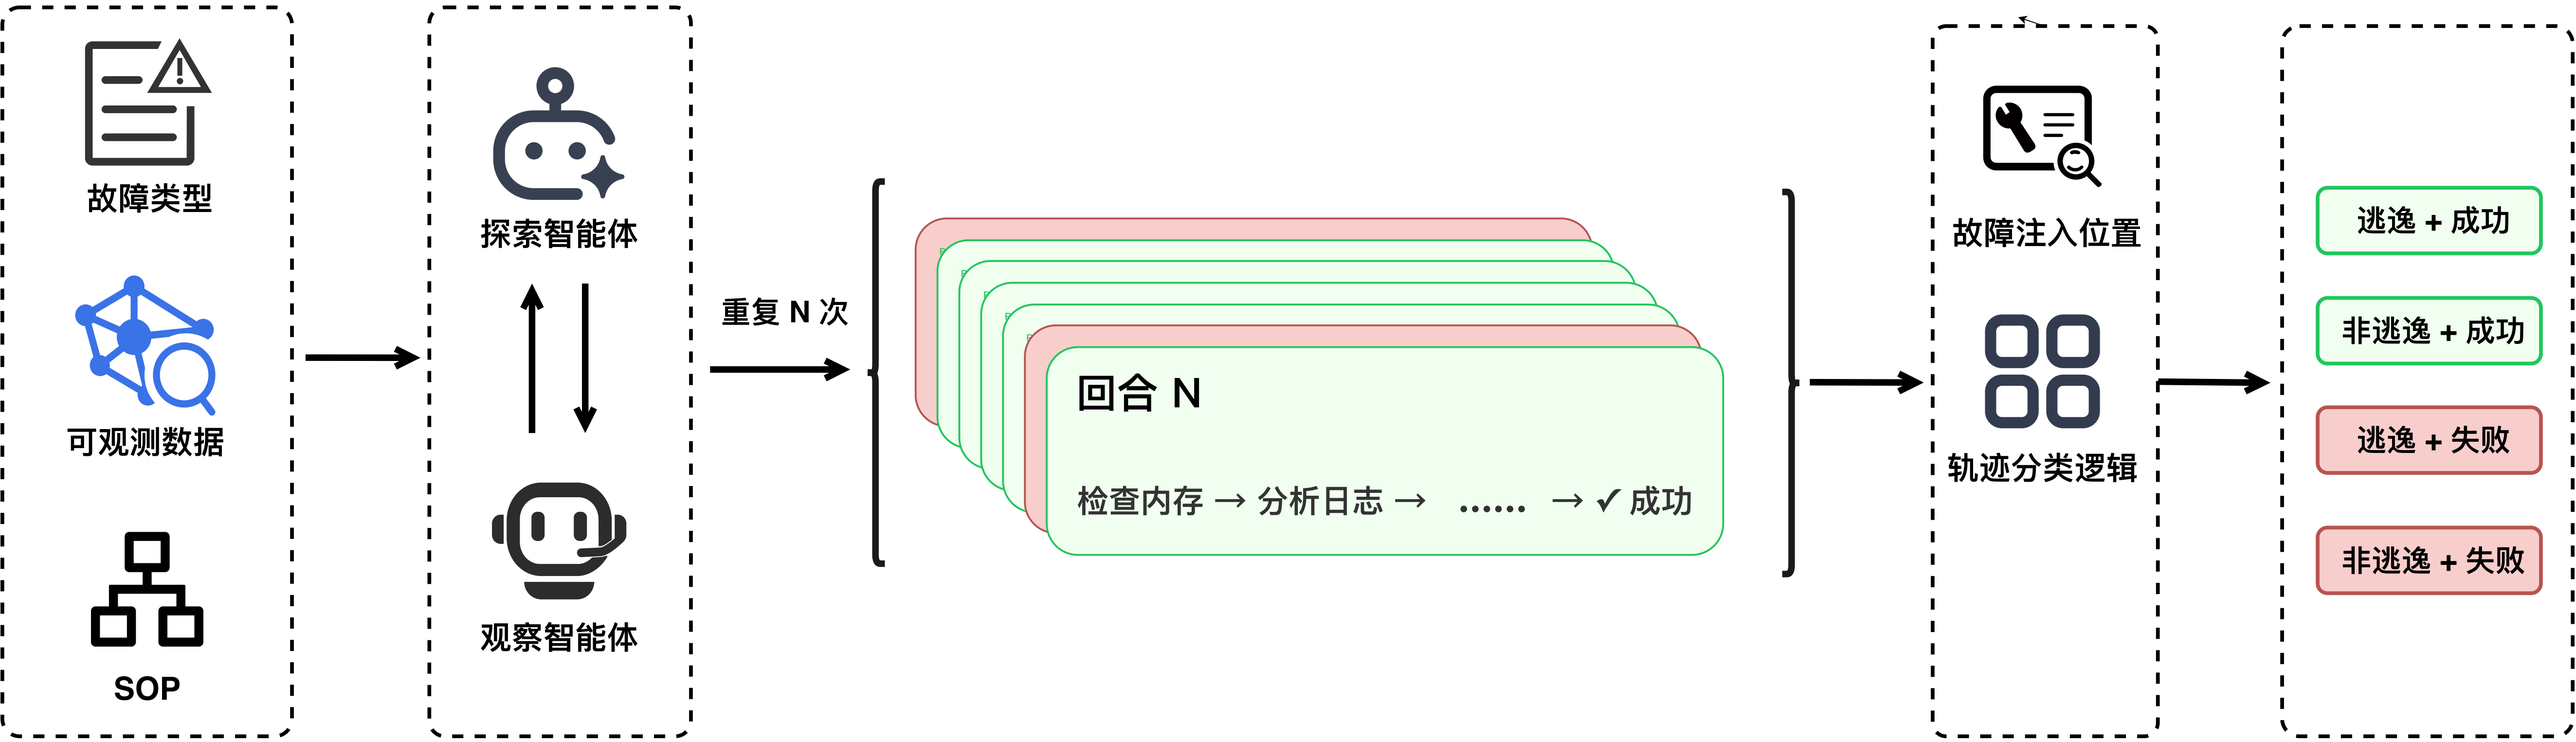
故障类型
可观测数据
SOP
探索智能体
观察智能体
重复 N 次
回合 N
检查内存 → 分析日志 → ..... → ✓ 成功
故障注入位置
轨迹分类逻辑
逃逸 + 成功
非逃逸 + 成功
逃逸 + 失败
非逃逸 + 失败

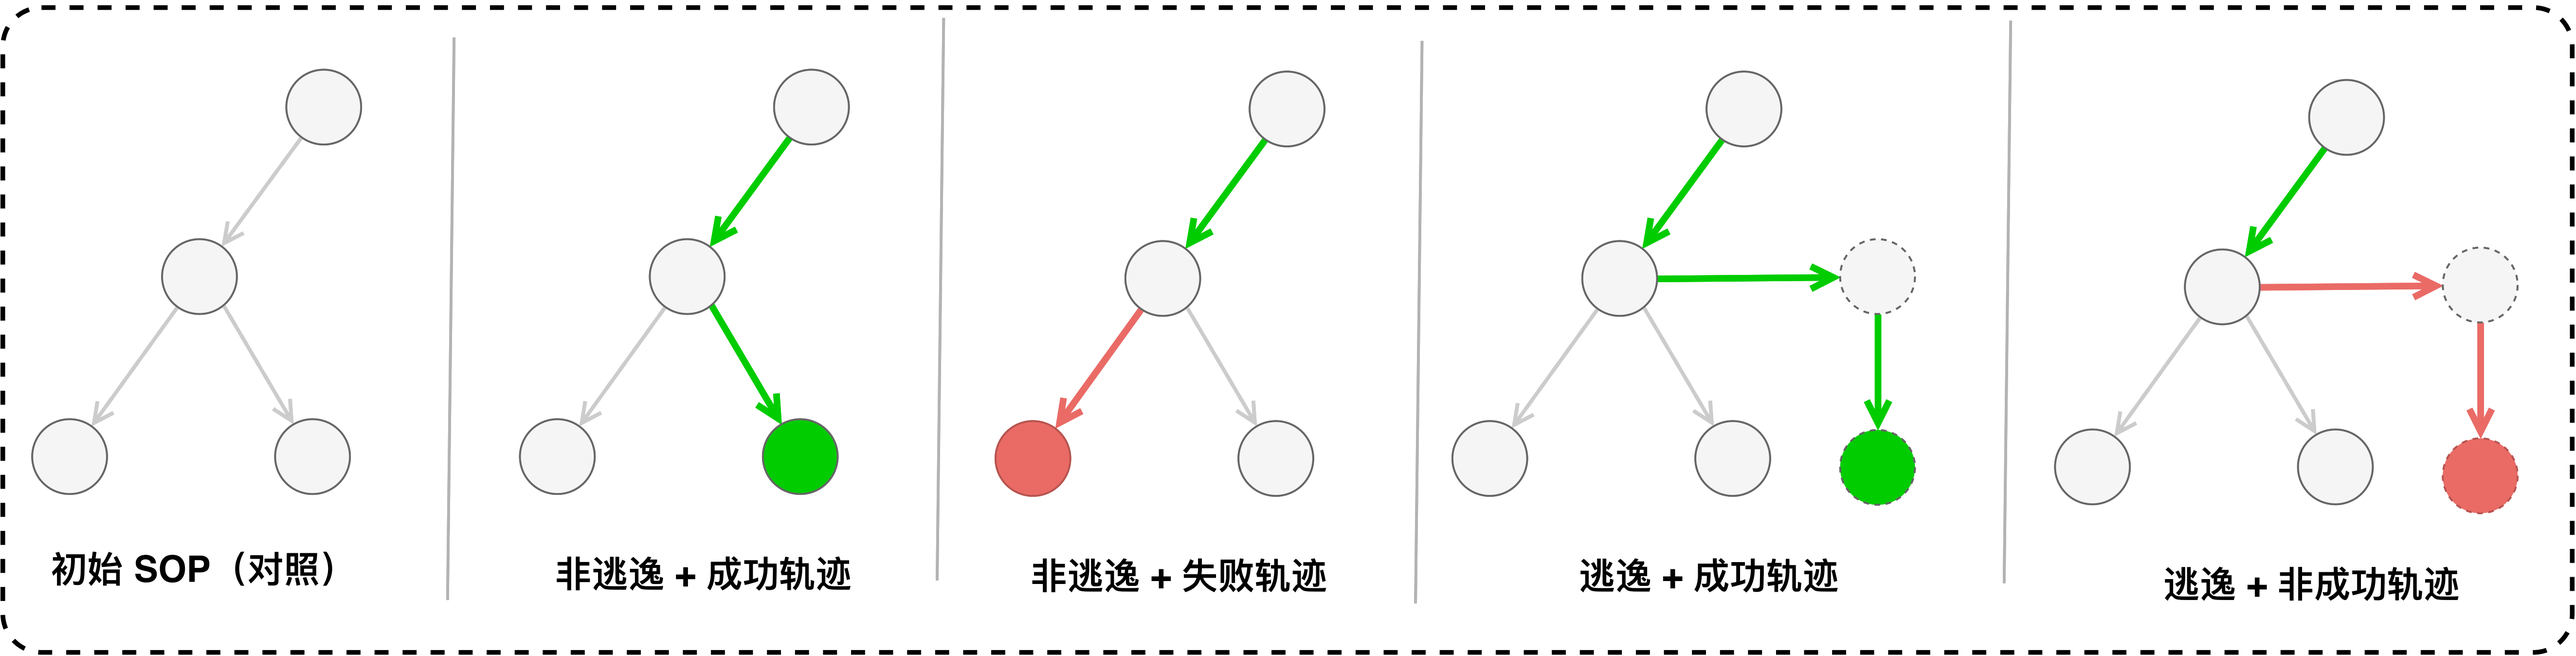
初始 SOP（对照）
非逃逸 + 成功轨迹
非逃逸 + 失败轨迹
逃逸 + 成功轨迹
逃逸 + 非成功轨迹